

Classificação de Personagens da Série *The Simpsons* com *Deep Features* e Fusão Estática de Classificadores

Autor Um¹, Autor Dois¹

¹Departamento de Computação (DACOM) – Universidade Tecnológica Federal do Paraná (UTFPR)
Campus Campo Mourão – Campo Mourão – PR – Brasil

{autor1, autor2}@alunos.utfpr.edu.br

1. Introdução

O reconhecimento automático de personagens em imagens é um problema clássico de visão computacional que combina extração de características visuais e classificação supervisionada. Neste trabalho aborda-se a classificação de cinco personagens da família principal da série *The Simpsons* — Bart, Homer, Lisa, Maggie e Marge — a partir de imagens estáticas. O desafio é relevante porque as classes apresentam forte semelhança de paleta de cores e traços visuais (tom amarelo da pele, contornos simples), além de desbalanceamento entre classes, o que torna o problema sensível tanto à qualidade do descritor de características quanto à robustez do classificador.

A proposta deste trabalho é um *pipeline* de classificação que (i) extrai *deep features* de um modelo pré-treinado *Vision Transformer* (ViT-large), (ii) avalia um conjunto de 20 classificadores cobrindo cinco famílias distintas (k-NN, Árvore de Decisão, SVM, *Random Forest* e MLP) e (iii) aplica métodos de **fusão estática de classificadores** (*voting*, *weighted voting*, *Top-K ensemble* e *stacking*) para superar o melhor classificador individual. O sistema é avaliado em dois protocolos complementares: validação cruzada de 10 *folds* sobre o conjunto de treino e avaliação *holdout* sobre o conjunto de validação fornecido com a base. Reportam-se acurácia, *F1-score* macro e matrizes de confusão, além de uma análise do impacto da fusão e dos pontos fortes e fracos do sistema.

2. Materiais e Métodos

2.1. Base de Dados

A base *Simpsons* utilizada é composta por imagens no formato BMP, divididas em cinco classes correspondentes aos personagens. Adotou-se a divisão proposta nos próprios arquivos da base: um conjunto de **treino** com 226 imagens e um conjunto de **validação** (*holdout*) com 95 imagens. A Tabela 1 apresenta a distribuição de imagens por classe no conjunto de treino, evidenciando o desbalanceamento (Bart é a classe majoritária e Maggie/Marge as minoritárias).

Tabela 1. Distribuição de imagens por classe no conjunto de treino.

Classe	Bart	Homer	Lisa	Maggie	Marge
<i>Imagens (treino)</i>	78	61	33	30	24

2.2. Extração de Características (*Deep Features*)

Em vez de descritores manuais (cor, textura, forma), optou-se por *deep features*: representações extraídas de uma rede neural profunda pré-treinada, usadas como vetor de características de entrada para classificadores clássicos. Empregou-se o modelo *Vision Transformer* `google/vit-large-patch16-224-in21k`, pré-treinado no ImageNet-21k.

Cada imagem é redimensionada e normalizada conforme o pré-processamento do modelo; a partir da saída `last_hidden_state` do ViT calcula-se a média ao longo dos *tokens* (*mean pooling*), gerando um vetor de **1024 características** por imagem. Esse vetor é então padronizado (*z-score*, `StandardScaler`) com estatísticas estimadas exclusivamente no conjunto de treino, evitando vazamento de informação para a validação. A escolha do ViT-large justifica-se por capturar relações globais na imagem via atenção, produzindo representações altamente discriminativas mesmo com poucos exemplos de treino por classe.

2.3. Classificadores

Construiu-se um *pool* de **20 classificadores** que cobre as cinco famílias vistas na disciplina, variando hiperparâmetros relevantes (Tabela 2). Todos os modelos foram implementados com a biblioteca *scikit-learn*.

Tabela 2. *Pool* de 20 classificadores e seus hiperparâmetros.

Família	Variações
k-NN	$k \in \{1, 3, 5, 7\}$
Árvore de Decisão	profundidade $\in \{5, 10, 15\}$; critério <i>entropy</i>
SVM	RBF com $C \in \{0,1; 1,0; 10,0\}$; <i>kernel</i> linear
<i>Random Forest</i>	$\{10, 50, 100, 200\}$ árvores
MLP	topologias (50), (100), (50, 25), (100, 50)

2.4. Fusão Estática de Classificadores

Para explorar a complementaridade entre os modelos, aplicaram-se cinco estratégias de combinação estática sobre o *pool* de 20 classificadores:

- **Hard Voting:** voto majoritário entre as predições de classe.
- **Soft Voting:** média das probabilidades *a posteriori*.
- **Weighted Soft Voting:** *soft voting* ponderado pela acurácia individual de cada classificador (modelos melhores pesam mais).
- **Top-K Ensemble:** *soft voting* apenas com os K melhores classificadores ($K \in \{5, 8, 10, 12, 15\}$), descartando modelos fracos.
- **Stacking:** meta-aprendizado em que uma Regressão Logística (nível 1) é treinada sobre as predições dos 20 classificadores (nível 0), com *passthrough* das características originais.

2.5. Protocolo de Avaliação e Métricas

Adotaram-se dois protocolos: (A) **Teste** via validação cruzada estratificada de 10 *folds* sobre o treino e (B) **Validação** via *holdout*, treinando no conjunto de treino completo e avaliando no conjunto de validação. As métricas reportadas são acurácia, *F1-score* macro (média não-ponderada por classe, adequada a bases desbalanceadas) e a matriz de confusão $N \times N$ ($N = 5$) em percentual de acertos/erros por classe.

3. Resultados e Discussão

3.1. Classificadores Individuais (Protocolo A — 10-fold CV)

A Tabela 3 apresenta o desempenho dos 20 classificadores na validação cruzada de 10 *folds*. A Figura 1 mostra o comparativo visual de acurácia (com os *baselines* de fusão) e a Figura 2 a média por família.

Tabela 3. Acurácia e *F1-score* macro dos classificadores individuais (10-fold CV).
Em destaque, os três melhores.

Classificador	Acurácia (%)	F1-macro (%)
MLP (50)	88,05	86,85
SVM-Linear	87,61	87,45
MLP (100,50)	87,61	86,48
MLP (100)	85,84	85,90
SVM-RBF (C=10,0)	84,51	83,44
MLP (50,25)	82,74	82,99
SVM-RBF (C=1,0)	81,86	81,63
kNN (k=3)	81,86	80,51
RF (200 árvores)	79,65	76,69
kNN (k=5)	79,20	75,14
RF (100 árvores)	78,76	75,34
kNN (k=1)	77,88	77,11
kNN (k=7)	77,88	74,81
RF (50 árvores)	74,78	69,19
RF (10 árvores)	66,37	60,10
DT (prof=10)	49,12	45,01
DT (entropy)	49,12	43,48
DT (prof=15)	49,12	45,01
DT (prof=5)	46,90	42,20
SVM-RBF (C=0,1)	34,51	10,26

Observa-se que as famílias **MLP** e **SVM** dominam o ranking, com o melhor classificador individual (MLP com camada de 50 neurônios) atingindo **88,05%** de acurácia. As **Árvores de Decisão** isoladas são o ponto fraco ($\approx 49\%$), por não explorarem a alta dimensionalidade das *deep features* de forma robusta, e o SVM-RBF com $C = 0,1$ colapsa (34,51%) por regularização excessiva. Esse contraste evidencia a importância da escolha de hiperparâmetros e motiva a fusão, que pode tanto agregar a força dos melhores modelos quanto ser penalizada pela inclusão dos fracos.




Figura 1. Acurácia dos 20 classificadores individuais e dos *baselines* de fusão (10-fold CV), coloridos por família.




Figura 2. Acurácia média por família de classificador (10-fold CV).

3.2. Fusão de Classificadores (Protocolo A — 10-fold CV)

A Tabela 4 e a Figura 3 resumem o desempenho dos métodos de fusão frente ao melhor classificador individual. O **Top-12 Ensemble** foi o melhor método, alcançando **89,38%** de acurácia e **89,18%** de F1-macro — um ganho de **+1,33 ponto percentual** sobre o melhor individual (MLP 50). O *Stacking* ficou logo atrás (88,94%), e o *Soft Voting* com os 20 classificadores (88,05%) apenas empatou com o melhor individual, justamente porque inclui os modelos fracos (Árvores de Decisão e SVM-RBF $C = 0,1$) que arrastam a média para baixo.

Tabela 4. Desempenho dos métodos de fusão (10-fold CV). Δ em relação ao melhor individual (MLP 50, 88,05%).

Método	Acurácia (%)	F1-macro (%)	Δ (p.p.)
Melhor individual (MLP 50)	88,05	86,85	—
Hard Voting (20 clf)	84,51	83,53	−3,54
Soft Voting (20 clf)	88,05	87,84	+0,00
Weighted Soft Voting (20 clf)	87,61	87,57	−0,44
Top-12 Ensemble (Soft)	89,38	89,18	+1,33
Stacking (LR meta-learner)	88,94	88,89	+0,89




Figura 3. Comparativo dos métodos de fusão vs. melhor individual (10-fold CV).

Impacto da fusão. O resultado central é que a fusão *seletiva* (Top-K e Stacking) supera tanto o melhor individual quanto a fusão ingênua com todos os modelos. A Figura 4 mostra que a acurácia do Top-K cresce à medida que se removem os classificadores fracos, atingindo o ótimo em $K = 12$ e caindo levemente ao incluir modelos piores. Já o *Hard Voting* foi o pior método (84,51%), pois o voto majoritário não pondera a confiança das predições e é dominado pelos muitos modelos medianos.




Figura 4. Impacto do tamanho K no *Top-K Ensemble*.

3.3. Matrizes de Confusão

A Figura 5 apresenta as matrizes de confusão (em %) do melhor classificador individual e do melhor método de fusão (Top-12) na validação cruzada. A análise por classe revela que os principais erros concentram-se entre as personagens femininas **Maggie** e **Marge** (classes minoritárias, com menos exemplos de treino), enquanto Bart e Homer — classes majoritárias e visualmente mais distintas — são classificados com alta taxa de acerto. A fusão Top-12 reduz parte dessas confusões, melhorando o equilíbrio entre as classes (refletido no F1-macro).




Figura 5. Matrizes de confusão (%) na validação cruzada: melhor individual, MLP (50) (esquerda), e melhor fusão, Top-12 (direita).

3.4. Avaliação no Conjunto de Validação (Protocolo B — *holdout*)

Para verificar a capacidade de generalização do sistema, treinaram-se todos os modelos no conjunto de treino completo e avaliou-se o conjunto de validação *holdout* (95 imagens não vistas no treino). As Tabelas 5 e 6 reportam os resultados.

Tabela 5. Cinco melhores classificadores individuais no conjunto de validação (*holdout*).

Classificador	Acurácia (%)	F1-macro (%)
MLP (50,25)	84,21	84,56
MLP (100)	82,11	82,24
MLP (50)	81,05	79,27
SVM-Linear	78,95	78,06
SVM-RBF (C=10,0)	76,84	77,19

de Decisão isoladas têm desempenho fraco e, quando incluídas na fusão ingênua, degradam o *Hard/Soft Voting*; (iii) o custo computacional da extração de *deep features* e do *Stacking* é elevado em CPU.

4. Conclusão

Este trabalho apresentou um sistema de classificação de personagens de *The Simpsons* baseado em *deep features* do ViT-large e em um *pool* de 20 classificadores combinados por fusão estática. A melhor configuração — *Top-12 Ensemble* — atingiu **89,38%** de acurácia na validação cruzada de 10 *folds*, superando o melhor classificador individual em 1,33 ponto percentual, com resultados consistentes também no conjunto de validação *holdout*. Demonstrou-se que a fusão *seletiva* de classificadores é mais eficaz que a combinação ingênua de todos os modelos, e que a maior parte dos erros decorre do desbalanceamento entre classes. Como trabalhos futuros, sugere-se a avaliação de descritores adicionais (p.ex. *deep features* de redes convolucionais como ResNet/EfficientNet) e técnicas de balanceamento de classes para reduzir as confusões entre as personagens minoritárias.

Referências

- [1] Dosovitskiy, A. et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ICLR*.
- [2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [3] Kuncheva, L. I. (2014). *Combining Pattern Classifiers: Methods and Algorithms*. 2nd ed. Wiley.
- [4] Wolpert, D. H. (1992). Stacked Generalization. *Neural Networks*, 5(2), 241–259.